UNIVERSIDADE FEDERAL DO CEARÁ

PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E DE COMPUAÇÃO

MANOEL ERIC NASCIMENTO DE OLIVEIRA

CLASSIFICAÇÃO DE PATOLOGIAS DA COLUNA VERTEBRAL UTILIZANDO OS ALGORITMOS KNN, LDA E QDA

SOBRAL

2026

SUMÁRIO

1 INTRODUÇÃO 2

1.1 Base de dados 2

1.2 Algoritmos 2

2 RESULTADOS 4

2.1 Com duas classes 4

2.1.1 KNN 4

2.1.2 LDA 4

2.1.3 QDA 5

2.2 Com três classes 6

2.2.1 KNN 6

2.2.2 LDA 6

2.2.3 QDA 7

3 CONSIDERAÇÕES FINAIS 8

1 INTRODUÇÃO

1.1 Base de dados

A base de dados **Vertebral Column** é um conjunto clínico utilizado para classificar condições da coluna vertebral a partir de medições biomecânicas.

Cada amostra possui **6 atributos numéricos**:

- *pelvic incidence*
- *pelvic tilt*
- *lumbar lordosis angle*
- *sacral slope*
- *pelvic radius*
- *degree spondylolisthesis*

Além disso a base de dados possui duas variações.A primeira com duas classes: Pacientes com Patologia(AB) e Pacientes Saudáveis (Normal). A segunda com três classes: Hérnia de disco(DH), Deslizamento Vertebral(SL) e Pacientes Saudáveis(NO).

1.2 Algoritmos

k-NN (k-Nearest Neighbors)

O **k-NN** é um algoritmo de aprendizagem baseada em instâncias que classifica um novo dado com base na proximidade. Ele não assume uma distribuição estatística subjacente, utilizando a distância (geralmente Euclidiana) para identificar os vizinhos mais próximos e atribuir a classe por voto majoritário.

$$d(x,x_i) = \sqrt{\sum_{j=1}^{n} (x_j - x_{ij})^2} \tag{1.1}$$

$$\hat{y} = \text{argmax}_c \sum_{i \in N_k(x)} I(y_i = c) \tag{1.2}$$

LDA (Linear Discriminant Analysis)

A **Análise Discriminante Linear** busca encontrar uma combinação linear de características que separe duas ou mais classes. O LDA assume que todas as classes compartilham

a mesma matriz de covariância (Σ), resultando em fronteiras de decisão lineares. É eficiente quando os dados seguem uma distribuição normal.

$$g_c(x) = x^T \Sigma^{-1} \mu_c - \frac{1}{2} \mu_c^T \Sigma^{-1} \mu_c + \log P(c) \tag{1.3}$$

QDA (Quadratic Discriminant Analysis)

Diferente do LDA, a **Análise Discriminante Quadrática** permite que cada classe tenha sua própria matriz de covariância (Σ_c). Isso resulta em fronteiras de decisão quadráticas, oferecendo maior flexibilidade para capturar padrões complexos nos dados, embora exija mais amostras para estimar os parâmetros com precisão.

$$g_c(x) = -\frac{1}{2} \log |\Sigma_c| - \frac{1}{2} (x - \mu_c)^T \Sigma_c^{-1} (x - \mu_c) + \log P(c) \tag{1.4}$$

2 RESULTADOS

Para todos os algoritmos foi utilizado o método de validação *Leave-One-Out*, treina com $N-1$ amostras e testa com o restante.

2.1 Com duas classes

2.1.1 KNN

Tabela 1 – Resultados do Classificador k-NN variando o parâmetro k.

k	Acurácia (Sem Normalização)	Acurácia (Com Z-Score)
1	**84,19%**	82.58%
2	84,19%	82.58%
3	82,58%	80.65%
4	83,55%	80.32%
5	83,87%	81.94%

Figura 1 – Acurácia para $k = 1,2,3,4,5$

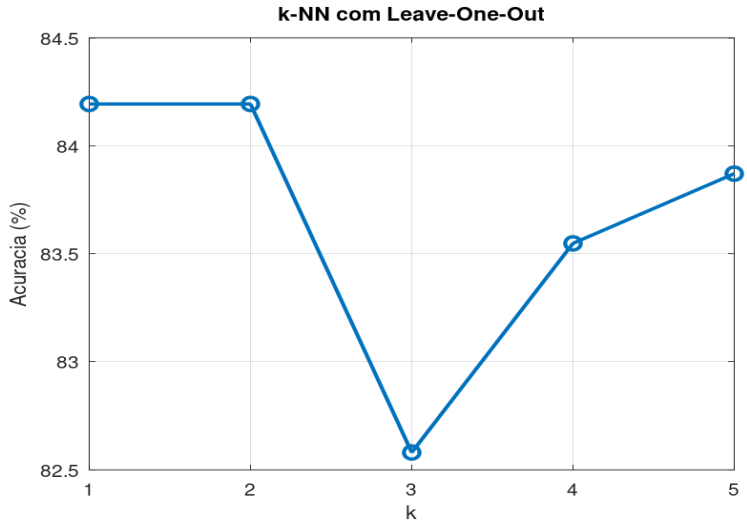

Fonte: Elaborado pelo autor.

2.1.2 LDA

Tabela 2 – Resultado da Análise Discriminante Linear (LDA).

Algoritmo	Método de Validação	Acurácia Final
LDA	Leave-One-Out	**84,19%**

Figura 2 – Superfície de decisão com LDA

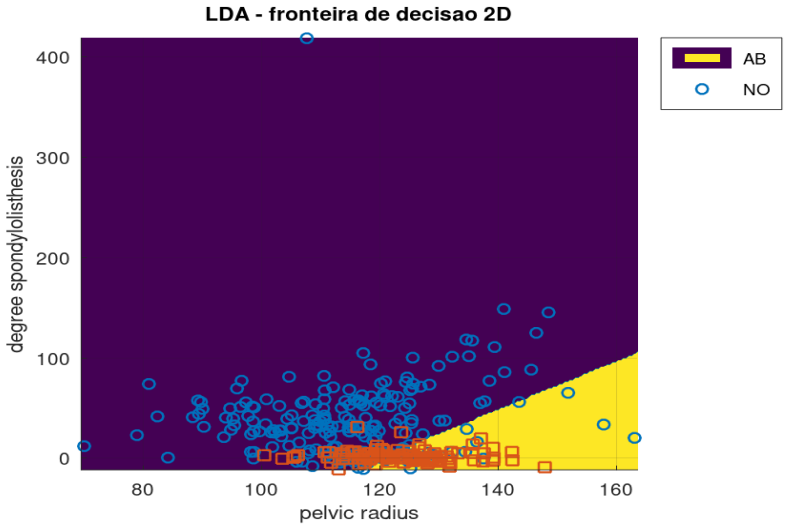

Fonte: Elaborado pelo autor.

2.1.3 QDA

Tabela 3 – Resultado da Análise Discriminante Quadrática (QDA).

Algoritmo	**Método de Validação**	**Acurácia Final**
QDA	Leave-One-Out	82,58%

Figura 3 – Superfície de decisão com QDA

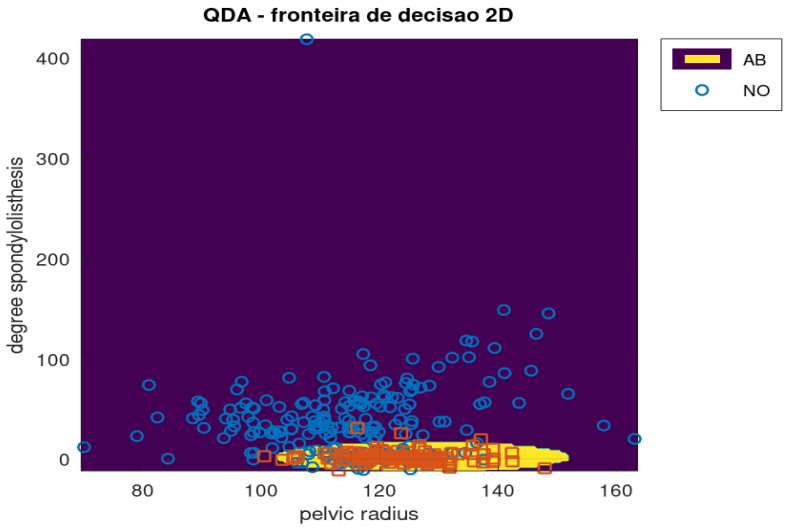

Fonte: Elaborado pelo autor.

2.2 Com três classes

2.2.1 KNN

Tabela 4 – Resultados do Classificador k-NN variando o parâmetro k.

k	Acurácia (Sem Normalização)	Acurácia (Com Z-Score)
1	**83.87%**	80.65%
2	83.87%	80.65%
3	81.29%	77.42%
4	83.55%	77.10%
5	83.23%	79.35%

Figura 4 – Acurácia para $k = 1, 2, 3, 4, 5$

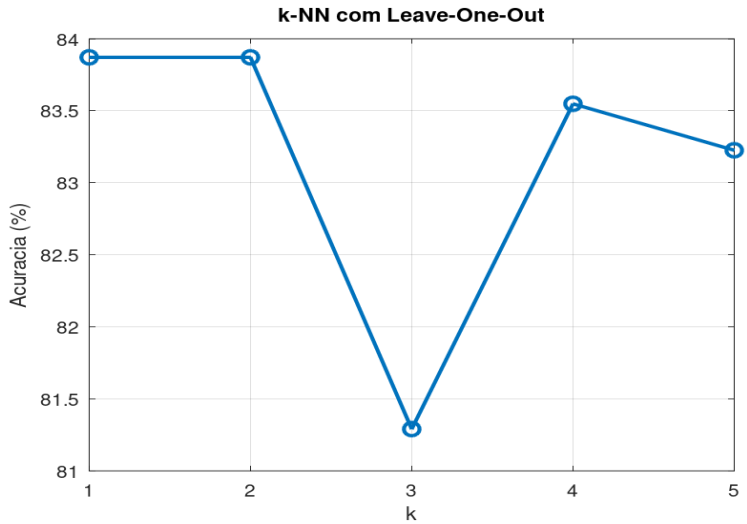

Fonte: Elaborado pelo autor.

2.2.2 LDA

Tabela 5 – Resultado da Análise Discriminante Linear (LDA).

Algoritmo	Método de Validação	Acurácia Final
LDA	Leave-One-Out	**80.65%**

Figura 5 – Superfície de decisão com LDA

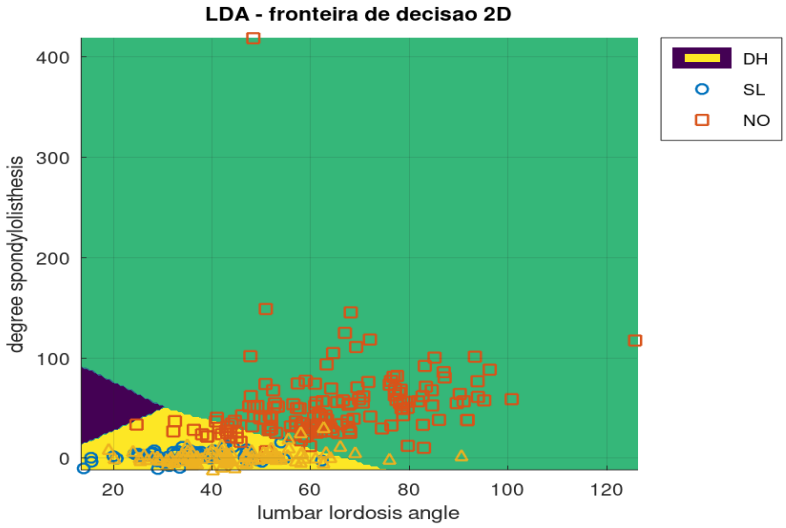

Fonte: Elaborado pelo autor.

2.2.3 QDA

Tabela 6 – Resultado da Análise Discriminante Quadrática (QDA).

Algoritmo	**Método de Validação**	**Acurácia Final**
QDA	Leave-One-Out	84.84%

Figura 6 – Superfície de decisão com QDA

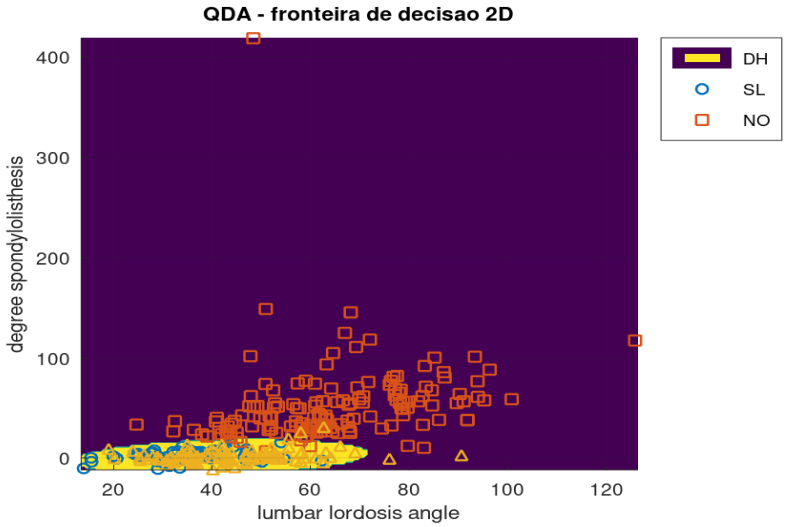

Fonte: Elaborado pelo autor.

3 CONSIDERAÇÕES FINAIS

Os resultados obtidos demonstram que a aplicação da normalização *Z-Score* não resultou em ganho de desempenho para o algoritmo k-NN em nenhum dos cenários testados, sugerindo que a escala original dos atributos ortopédicos já favorece a métrica de distância ou que o redimensionamento das variâncias prejudica a estrutura de vizinhança dos dados. No cenário de duas classes, o empate em acurácia (84,19%) entre o **LDA** e o **k-NN** ($k = 1$) indica uma separabilidade com tendência linear entre pacientes normais e anormais. Por outro lado, na classificação de três classes, o **QDA** apresentou o melhor desempenho (84,84%), evidenciando que a distribuição das classes específicas (hérnia de disco e espondilolistese) possui matrizes de covariância distintas e fronteiras de decisão não lineares, as quais são melhor capturadas pela flexibilidade do modelo quadrático.